

CS2 AI Video Commentator: Görsel-Dil Modelleri ile Otomatik Türkçe Oyun Açıklaması Üretimi

Berk Burhan Cesur

Öğrenci No: 230212023 · Ders: Derin Öğrenme · Öğretim Üyesi: Dr. Murat Şimşek

Mayıs 2025

Öz — Bu çalışmada, Counter-Strike 2 (CS2) oyununa ait video kliplerini otomatik olarak analiz edip Türkçe açıklama üreten hibrit bir yapay zeka sistemi geliştirilmiştir. Sistem; görsel anlama için InternVL2-8B görsel-dil modelini (VLM) ve nesne tespiti için YOLO tabanlı modelleri bir arada kullanmaktadır. Faceit ve Allstar.gg platformlarından derlenen 34 adet CS2 highlight klipi ve bu kliplere ait el ile hazırlanmış Türkçe açıklamalardan oluşan bir veri seti kullanılmıştır. Geliştirilen pipeline; video temizleme, aksiyon yoğun frame seçimi, harita tespiti, silah tespiti ve Türkçe açıklama üretimi aşamalarından oluşmaktadır. 32 video üzerinde yapılan değerlendirmede ROUGE-1 = 0.298, ROUGE-2 = 0.053 ve ROUGE-L = 0.207 skorları elde edilmiştir. Harita tespiti başarılı biçimde çalışmış; ancak silah tespiti ve detaylı aksiyon açıklaması hedeflerine tam anlamıyla ulaşamamıştır. Elde edilen bulgular, genel amaçlı VLM’lerin domain-spesifik oyun videolarında ve düşük kaynaklı dil ortamlarında sergilediği kısıtlamaları somut biçimde ortaya koymaktadır.

Anahtar Kelimeler: Video Captioning, Görsel-Dil Modeli, CS2, YOLO, ROUGE, Few-Shot Prompting, Türkçe Doğal Dil İşleme

1. GİRİŞ

Counter-Strike 2 (CS2), dünya genelinde milyonlarca izleyiciye ulaşan profesyonel bir e-spor dalıdır. Maç anlarının otomatik açıklanması; içerik üreticilerin üretkenliğini artırabilmekte, yayın platformlarına özgün değer katabilmekte ve erişilebilirliği genişletebilmektedir.

Bu çalışma, CS2 video kliplerini otomatik olarak analiz edip Türkçe açıklama üreten uçtan uca bir yapay zeka sistemi geliştirmeyi amaçlamaktadır. Sistem; InternVL2-8B [1] görsel-dil modeli ile YOLO tabanlı nesne tespiti modellerinin birleştirildiği hibrit bir pipeline üzerine kurulmuştur.

Proje sonunda ideal bir sistem elde edilememiş olmakla birlikte, CS2 gibi domain-spesifik videolarda büyük dil modellerinin davranışı ve kısıtlamaları somut biçimde gözlemlenmiştir.

2. İLGİLİ ÇALIŞMALAR

Video captioning alanında MSVD ve MSR-VTT gibi genel amaçlı veri setleri üzerinde eğitilen modeller yüksek BLEU ve ROUGE skorları elde etse de domain-spesifik videolarda bu başarı sürdürülememektedir [4].

CS2 için nesne tespiti modelleri geliştirilmiş olmakla birlikte [5], Türkçe oyun video açıklaması üretimine yönelik herhangi bir çalışmaya rastlanmamıştır. Bu çalışma, söz konusu alanda öncü nitelikte bir girişim olarak değerlendirilebilir.

3. VERİ SETİ

3.1. Video Klipleri ve Etiketler

Veri seti, Faceit ve Allstar.gg platformlarından derlenen 34 adet CS2 highlight klipinden oluşmaktadır. Klipler yak-

laşık 20 saniye uzunluğunda olup Mirage, Nuke, Ancient ve Anubis haritalarını kapsamaktadır. Her klip için proje sahibi tarafından el ile Türkçe açıklamalar hazırlanmıştır:

“Oyuncu, Mirage haritasında AK-47 ile A bölgesine gelen rakipleri tek tek etkisiz hale getiriyor.”

Tablo 1: Veri seti özeti.

Özellik	Değer
Toplam video	34
Ort. süre	~20 sn
Temizleme sonrası	~10–12 sn
Etiket dili	Türkçe
Haritalar	Mirage, Nuke, Ancient, Anubis
Platform	Faceit / Allstar.gg

3.2. Veri Ön İşleme

Faceit highlight kliplerinin son 8–10 saniyesi oyun görüntüsü yerine bir özet ekranı içermektedir. Bu bölümün model performansını olumsuz etkilememesi amacıyla tüm videolar FFmpeg kullanılarak son 10 saniye kesilmiştir.

4. YÖNTEM

4.1. Genel Pipeline

Geliştirilen sistem altı aşamadan oluşmaktadır: (1) FFmpeg ile video temizleme, (2) YOLO ve piksel hareketi puanlamasıyla highlight frame seçimi, (3) harita tespiti, (4) silah tespiti, (5) İngilizce açıklama üretimi ve (6) Google Translate ile Türkçeye çeviri.

4.2. InternVL2-8B

InternVL2-8B [1], OpenGVLab tarafından geliştirilen açık kaynaklı bir görsel-dil modelidir. bfloat16 formatında, device_map =auto ayarıyla NVIDIA A100 GPU üzerinde çalıştırılmıştır. Model doğrudan Türkçe çıktı üretmediğinden açıklamalar önce İngilizce üretilip ardından çevrilmiştir.

Model gerçek anlamda video işleyememekte; bu nedenle her video eşit aralıklı frame'lere bölünmüş ve sırayla modelle sunulmuştur. Bu yaklaşım frame'ler arası zamansal bağlamanın yakalanamadığı temel bir kısıtlamayı beraberinde getirmektedir.

4.3. YOLO Modelleri

İki farklı YOLO modeli kullanılmıştır. **CS2 Player Modeli:** Vombit/yolo12n_cs2 [5] modeli CT ve T oyuncularını tespit ederek aksiyon yoğun frame seçimini desteklemiştir. **İnce Ayarlı Silah Modeli:** Roboflow CS2 silah veri setiyle YOLOv8n modeli 30 epoch ince ayar uygulanmıştır.

Tablo 2: YOLO silah modeli eğitim sonuçları.

Metrik	Değer
Epoch	30
Eğitim süresi	0.071 saat
mAP50	0.804
mAP50-95	0.587
Kesinlik	0.927
Duyarlılık	0.696

4.4. Few-Shot Prompting

Modelin CS2 domain'ine uyumunu artırmak amacıyla few-shot prompting denenmiştir. Veri setinden seçilen videoların frame'leri ve ground truth açıklamaları modele örnek olarak sunulmuş; ardından test videosu için açıklama üretmesi istenmiştir. 3-shot yapılandırması en iyi ROUGE-L sonucunu vermiştir.

5. DENEYLER VE SONUÇLAR

5.1. ROUGE Değerlendirmesi


Üretilen açıklamaları ROUGE metrikleriyle değerlendirdik. Ground truth açıklamalarımız Türkçeydi, modelin çıktıları ise İngilizce geliyordu. İkisini karşılaştırmak için Türkçe açıklamaları Google Translate ile İngilizceye çevirdik. Aslında bu da biraz haksız bir karşılaştırma, çeviri sırasında bazı şeyler kayboluyor ama elimizdeki en mantıklı yol buydu.

Tablo 3: Final pipeline ROUGE sonuçları (32 video).

Metrik	Skor
ROUGE-1	0.298
ROUGE-2	0.053
ROUGE-L	0.207

Tablo 4: Yapılandırma karşılaştırması.

Yapılandırma	ROUGE-L
Zero-shot	0.117
Prompt iyileştirme	0.094
İng. GT karşılaştırması	0.117
3-shot few-shot	0.202
Final pipeline	0.207



Şekil 1: ROUGE-L dağılım histogramı ve metrik karşılaştırması. Ortalama ROUGE-L = 0.207.

ROUGE-1 (0.298) ile ROUGE-2 (0.053) arasındaki belirgin fark, modelin tek kelime düzeyinde benzerlik kurabildiğini ancak ikili kelime örüntülerini yakalayamadığını göstermektedir.

5.2. Harita Tespiti

Harita tespiti, sistemin en başarılı bileşeni olmuştur. InternVL2-8B, CS2 haritalarını görsel doku ve mimari özelliklerinden tanıyabilmektedir.


Tablo 5: Harita dağılımı (32 video).

Harita	Video
Mirage	28
Nuke	3
Anubis	1

5.3. Silah Tespiti

İnce ayarlı YOLO modeli doğrulama setinde mAP50 = 0.804 elde etmiştir. Ancak gerçek video akışında silah tespiti tutarlı biçimde başarısız olmuş ve çıktı çoğunlukla *Unknown* olarak kalmıştır. Başlıca nedenler: (i) videolarda HUD kapalı olduğundan silah adı görünmemekte, (ii) 3B silah modelleri domain gap nedeniyle tanınamamakta, (iii) CS2'nin özel piksel fontu OCR tarafından okunamamaktadır.

5.4. Sistem Arayüzü



Şekil 2: Gradio demo arayüzü. Harita tespiti (Mirage) başarılı; silah tespiti Unknown.

6. TARTIŞMA

6.1. Temel Güçlükler

Zamansal bağlam eksikliği: Model videoyu kare kare işlediğinden “smoke içinden çıkıp headshot yaptı” gibi bir aksiyonu tek frame’den çıkarmak mümkün değildir.

Domain farkı: InternVL2-8B genel amaçlı bir modeldir. CS2 oyun içi görüntüleri eğitim verisinde son derece sınırlı yer kapladığından model, oyunun kendine özgü görsel dilini yeterince anlayamamaktadır.

Veri yetersizliği: İnce ayar için 34 video oldukça azdır; benzer akademik çalışmalar genellikle binlerce örnek gerekmektedir.

Dil uyumsuzluğu: Model İngilizce üretmekte, ground truth ise Türkçedir. İki aşamalı çeviri kaçınılmaz anlam kayıplarına yol açmaktadır.

6.2. ROUGE Metriğinin Sınırlılıkları

ROUGE, kelime örtüşmesine dayalı bir değerlendirme metriğidir. “Mirage” ve “player” gibi genel terimlerin her iki metinde bulunması skoru yükseltmekte; ancak bu metrik gerçek içerik kalitesini ölçememektedir. Domain-spesifik görevlerde insan değerlendirmesi veya BERTScore gibi anlam tabanlı metrikler çok daha güvenilir sonuçlar verecektir.

7. GELECEK ÇALIŞMALAR

Daha büyük veri seti: 34 video yerine en az 500–1000 video; harita, silah ve öldürme tipi gibi ayrıntılı Türkçe etiketlerle desteklenmelidir.

Gerçek video anlama: Frame-bazlı yaklaşım yerine Video-LLaMA veya VideoChat gibi zamansal bağlamı modelleyebilen mimariler kullanılmalıdır.

HUD açık veri: Silah adı, can gibi oyun içi göstergelerin görünür olduğu videolarla veri seti oluşturulmalıdır.

İnce ayar: LoRA veya QLoRA yöntemleriyle bir VLM’in CS2 domain’ine uyarlanması açıklama kalitesini önemli ölçüde artırılabilir.

Doğrudan Türkçe üretim: Modelin Türkçe çıktı üretmesi için ince ayar yapılması çeviri kaynaklı hataları ortadan kaldıracaktır.

8. SONUÇ

Açıkçası bu proje bize en çok şunu öğretti: hazır bir modeli alıp “çalıştır” demekle, domain’i spesifik bir problemde yeterli olmuyor. CS2 gibi hızlı tempolu, kendine özgü kelime daarcığı açısından zengin bir oyunda InternVL2 haritayı çoğunlukla doğru tahmin etti ama silahı neredeyse hiç doğru söyleyemedi. Deagle varken AK-47 dedi, Glock varken yine AK-47. Bunun sebebi modelin CS2’yi hiç görmemiş olması değil aslında, genel internet verisinde CS2 var muhtemelen ama birinci şahıs açısından silah modeli tanımayı öğrenmemiş. YOLO fine-tuning kısmında model metrik olarak gayet iyi göründü, mAP@50 = 0.832 aldık. Ama pratikte videolarda pek bir şey bulamadı. Sonradan anladık ki eğitim verisindeki açı ile bizim videolarımızdaki açı tamamen farklı, model yukarıdan bakışa alışmış biz ise birinci şahıs görüntü veriyoruz. Bu covariate shift denen şeyin tam karşılığı. 32 video üzerinde sonuçta ROUGE-1 = 0.298, ROUGE-2 = 0.053, ROUGE-L = 0.207 çıktı. Bu rakamlar düşük görünse de hiç fine-tuning yapmadan, sadece prompt mühendisliği ve YOLO entegrasyonu bu noktaya geldiğimizi düşününce aslında fena değil. Eğer bu çalışmayı ilerletecek olsak önce veri sorununu çözmek lazım. 35 video ile pek bir şey öğretilmiyor modele. HLTv demolarından 500 tane kesit çıkarsa, her biri elle etiketlenirse ve sonra LoRA ile fine-tuning yapılsa, çıktıların çok daha anlamlı olacağını düşünüyoruz. Son olarak şunu da söylemek istedik; bu proje temel olarak hedeflediğimiz yere ulaşamadı, bunu kabul ediyoruz. Ama ilerleyen aşamalarda profesyonel maç görüntüleri kullanılıp her sahne tek tek etiketlenirse gerçekten işe yarayan bir sistem çıkabilir. Yapay zeka spikeri ne kadar coşturur bilmiyoruz, o tartışmalı, ama görme engelli bireyler için çok daha detaylı ve akıcı bir anlatım sunabilir. Biz burada esas olarak kendi verilerimizle neler yapabildiğimizi görmek istedik, neyin çalışıp neyin çalışmadığını anlamak istedik. Umarız ileride birileri bu konuyu daha kapsamlı ele alır ve gerçekten bir faydası olur. Proje kodu ve veri seti GitHub üzerinden paylaşılacak.

KAYNAKÇA

Kaynaklar

- [1] Z. Chen et al., “InternVL: Scaling up Vision Foundation Models and Aligning for Generic Visual-Linguistic Tasks,” *CVPR*, 2024.
- [2] J. Redmon et al., “You Only Look Once: Unified, Real-Time Object Detection,” *CVPR*, 2016.
- [3] C. Y. Lin, “ROUGE: A Package for Automatic Evaluation of Summaries,” *ACL Workshop*, 2004.
- [4] D. Chen and W. B. Dolan, “Collecting Highly Parallel Data for Paraphrase Evaluation,” *ACL*, 2011.
- [5] Vombit, “YOLO CS2 Detection Model,” HuggingFace, 2024. https://huggingface.co/Vombit/yolo12n_cs2